谈楚抒（Chushu Tan）

AI 算法工程师 | 生物信息算法工程师 | 资深数据开发工程师
广东广州 | +86 18008428969 | chushuta@gmail.com
个人主页: chushuta-cmyk.github.io | **LinkedIn**: linkedin.com/in/chushu-tan-b6b0a011b

个人优势 / PROFILE SUMMARY

- **4 年以上跨行业复合实战背景**（金融与生物医药科技），兼具工业级大数据工程开发、机器学习/深度学习建模与复杂生物医学数据算法研发能力。
- **全栈工程与算法闭环**：精通从业务需求拆解、分布式 ETL 数据流、算法架构设计、模型训练优化、可解释性分析到生产环境 CI/CD 容器化部署的完整闭环。
- **核心系统交付经验**：主导并落地多款核心系统，涵盖基于 LangChain / LangGraph 的科研级 LLM Agent 架构、GCP 云原生大数据平台 ETL、脑电生理信号参数化提取与无泄露机器学习解码系统、以及 31 模块跨模态多组学自动化计算流水线。
- **严谨学术与统计素养**：第一作者论文发表于 *Neuroscience*（2026），合作论文发表于 *Viruses*（2025）。

核心技术栈 / TECHNICAL SKILLS

- **大模型与 AI 智能体开发**：LangChain、LangGraph、RAG（检索增强生成）、向量检索（FAISS / Chroma）、LLM API 深度集成、Agent 状态机与工作流路由、Prompt 工程、OCR + NLP 结构化解析
- **大数据平台与云工程**：Apache Spark / PySpark、Hive、Airflow、Hadoop、Prophecy、GCP（Google Cloud Platform）、阿里云、AWS、SQL、Linux Shell、Docker、Jenkins CI/CD、Git / GitHub
- **机器学习与统计建模**：XGBoost、LightGBM、Random Forest、SVM、Lasso / Elastic Net、CoxPH 生存分析、SHAP 可解释性归因、PyTorch、受试者独立留一验证（LOSO-CV）、多重检验校正（BH-FDR）、Meta 分析
- **生理信号与生物信息**：EEG 信号处理（MNE-Python / 频谱参数化 FOOOF / 拓扑图网络 OMST）、RNA-seq / scRNA-seq（Scanpy / Seurat / DESeq2）、GWAS / TWAS（PLINK2 / GEMMA / FUMA）、DNA 甲基化（minfi）、免疫解卷积（CIBERSORTx / MCP-counter）
- **工程流水线与容器化**：Nextflow、Snakemake、CWL、Conda 环境隔离、面向生产的代码重构、模块化 API 设计与单元测试

工作经历 / WORK EXPERIENCE

汇丰银行（HSBC） — 数据工程师（中电外包）

广东广州 | 2026.06 – 至今
技术栈：Prophecy, PySpark, GCP, Airflow, Jenkins, SQL, Git - **金融数据管道开发**：基于 Prophecy 与 PySpark 编写端到端分布式 ETL 批处理流水线，实现海量金融数据的高效清洗、标准化与特征转换，云端部署于 GCP。 - **调度监控与 CI/CD**：结合 Apache Airflow 进行复杂工作流依赖编排与任务监控；配置 Jenkins 自动化流水线实现代码测试、构建与持续部署，保障数据系统高可用。

广州海思医疗科技有限公司 — AI / 生物信息算法工程师

广东广州 | 2026.01 – 2026.04
技术栈：LangChain, LangGraph, RAG, Python, RESTful API, GWAS, TWAS - **科研级 LLM Agent 系统设计**：基于 LangChain 与 LangGraph 设计多智能体系统，开发 Tool-calling 接口，实现学术文献自动检索、跨库知识向量召回与生物医学工作流多步规划。 - **高通量基因组学生信流水线**：开发端到端全基因组发现算法管线，整合 GWAS 关联分析、TWAS 跨组织转录组表达预测与表观遗传学功能注释，支撑疾病标志物挖掘。

独立算法研究员 / 技术顾问 — 计算神经科学与多组学

远程 | 2023.10 – 至今
技术栈：MNE-Python, FOOOF/specparam, Scikit-learn, XGBoost, CoxPH, SHAP, R/Bioconductor, Docker - **生理信号算法与机器学习解码**：采用 MNE-Python 与 FOOOF 对多通道静息态脑电（EEG）进行频谱参数化解

耦，剔除 1/f 非周期背景并提取振荡特征；搭建严格无数据泄露的受试者独立（LOSO-CV）分类模型（AUC 0.881）与连续认知指标回归。 - **多组学自动化计算套件**：编写 31 个全自动化 R/Python 计算流，覆盖 13 个独立队列（N > 2,000），打通转录组（DESeq2/limma）、甲基化（minfi）及统计遗传学（FUMA/MAGMA）的大规模联合计算。 - **可解释性机器学习建模**：结合 XGBoost + CoxPH + SHAP 归因模型，对高维生物医学特征进行非线性风险预测与特征交互重要性解析。

汇丰银行（HSBC） — 高级数据分析师（外包）

广东广州 | 2024.03 – 2025.10
技术栈：Apache Spark, Hive, Airflow, OCR + NLP, LLM API, Python - **智能文本解析与实体识别**：主导设计 OCR + NLP 自动化文档处理流水线，实现多维度财报指标智能抽取与风险实体预警建模，大幅压缩人工审核周期。 - **大模型 API 赋能数据挖掘**：对接企业级 LLM API 完成海量非结构化文本的自动化信息清洗与风险分类，支持下游风控模型高效迭代。 - **分布式数据平台运维调优**：基于 Spark / Hive / Airflow 维护大规模分布式 ETL 流程，负责跨源数据校验、数据清洗及执行倾斜排查优化。

携云启源（Cloudna）生物科技 — 生物信息工程师

湖南长沙 | 2021.11 – 2023.10
技术栈：Nextflow, Snakemake, CWL, Docker, Linux, Python, R - **流程引擎与容器化部署**：使用 Nextflow、Snakemake 与 CWL 搭建高通量基因组分析流水线（WGS / WES），通过 Docker 容器化保障跨生产环境的完全复现与自动化调度。 - **算法平台与知识图谱构建**：搭建集成机器学习（Lasso / XGBoost / SVM）的数据分析平台；构建并维护 DbABC 数据库及其 Web 查询服务，整合多源数据构建关联知识图谱。

先赛生物 / 三济生物 — 生物信息工程师 / 算法开发

湖南长沙 | 2020.06 – 2021.10
技术栈：NGS 工具链, Linux Shell, Python, MySQL - **临床测序数据流**：构建从测序原始数据 BCL 拆分、质量控制、序列比对到变异检测的自动化流水线；搭建 MySQL 数据库存储与管理实验样本信息。

核心技术架构与算法项目 / TECHNICAL PROJECTS

- **基于 LangChain / LangGraph 的科研级自主智能体系统**
  - **技术点**：LangChain、LangGraph、RAG 向量检索（Chroma/FAISS）、Tool-Calling、多步反思与推理状态机、Prompt 工程
  - **架构概述**：面向复杂生物医学推理设计自主决策 Agent，打通 NCBI / PubMed / GEO 等学术 API 实时接口；利用向量混合检索实现长文本精准召回与自动化工作流动态编排。
- **生理信号特征参数化与无泄漏机器学习解码平台**
  - **技术点**：MNE-Python、FOOOF/specparam 频谱分解、LOSO-CV 严格防泄露验证、SVM 分类器、表面拉普拉斯（CSD）、OMST 图拓扑
  - **架构概述**：针对多通道脑电数据搭建信号预处理与特征工程流水线，剥离 1/f aperiodic 幂律背景，提取纯净周期特征；基于受试者独立留一交叉验证训练高泛化分类器（AUC = 0.881）与连续认知指标回归。
- **大规模多组学自动化计算套件（31 Reproducible Pipelines）**
  - **技术点**：R / Bioconductor (DESeq2, limma, minfi)、Python、FUMA / MAGMA、模块化数据编排、批次效应校正、细胞解卷积
  - **架构概述**：采用模块化解耦架构设计处理 13 个独立临床大队列，统一路径配置与依赖隔离，实现从原始矩阵清洗、差异表达、DNA 甲基化关联到 GWAS 遗传精细定位的标准化全自动分析。
- **金融智能文本挖掘与高并发分布式数据平台**
  - **技术点**：Apache Spark、PySpark、Apache Airflow、OCR、NLP、LLM API、GCP、Hive
  - **架构概述**：构建面向非结构化财报报告的自动化端到端提取管道，集成 OCR 与 NLP 抽取关键指标和风险实体；搭建千万级分布式数据批处理与调度任务，显著降低人工初筛成本。

教育背景 / EDUCATION

- **中国政法大学（CUPL）** | 应用心理学硕士（非全日制） | 2021 – 至今

  - *方向*：计算精神医学、认知神经科学与元分析
- **蒙纳士大学（Monash University，澳大利亚）** ｜ 信息技术硕士（M.IT） ｜ 2018 – 2019
  - *主修*：软件工程、分布式数据库架构、机器学习算法
- **纽约州立大学布法罗分校（SUNY Buffalo，美国）** ｜ 生物科学与心理学双学士（B.S.） ｜ 2011 – 2017
  - *主修*：分子生物学、进化遗传学、神经科学、生物统计学

学术发表与资质 / PUBLICATIONS & QUALIFICATIONS

1. **Tan C.*** (2026). Depression and amyloid-β across CSF, PET, and plasma biomarkers: a systematic review and meta-analysis. *Neuroscience*, 614, 82–93. DOI: 10.1016/j.neuroscience.2026.07.065（第一作者兼通讯作者）
2. **Alsaadawe M.†, Radman B. A.†, ..., Tan C., ..., Lyu X.*** (2025). From Viral Infection to Malignancy: The Dual Threat of EBV and COVID-19 in Cancer Development. *Viruses*, 17(9), 1195. DOI: 10.3390/v17091195（合作作者）

- **语言能力**：中文（母语） ｜ 英语（专业工作水平，海外双学位全英教育，熟练撰写全英文学术论文与技术方案）